Universidad San Francisco de Quito

Estudiante: Steve Tibán **Fecha:** 13/11/2026
Asignatura: Ciencia de Datos

1. Arquitectura

Se implementó una arquitectura ELT para el procesamiento de datos odontológicos adaptados al caso de estudio OralSolutions y orientados a preparar información para la predicción del abandono de tratamientos.

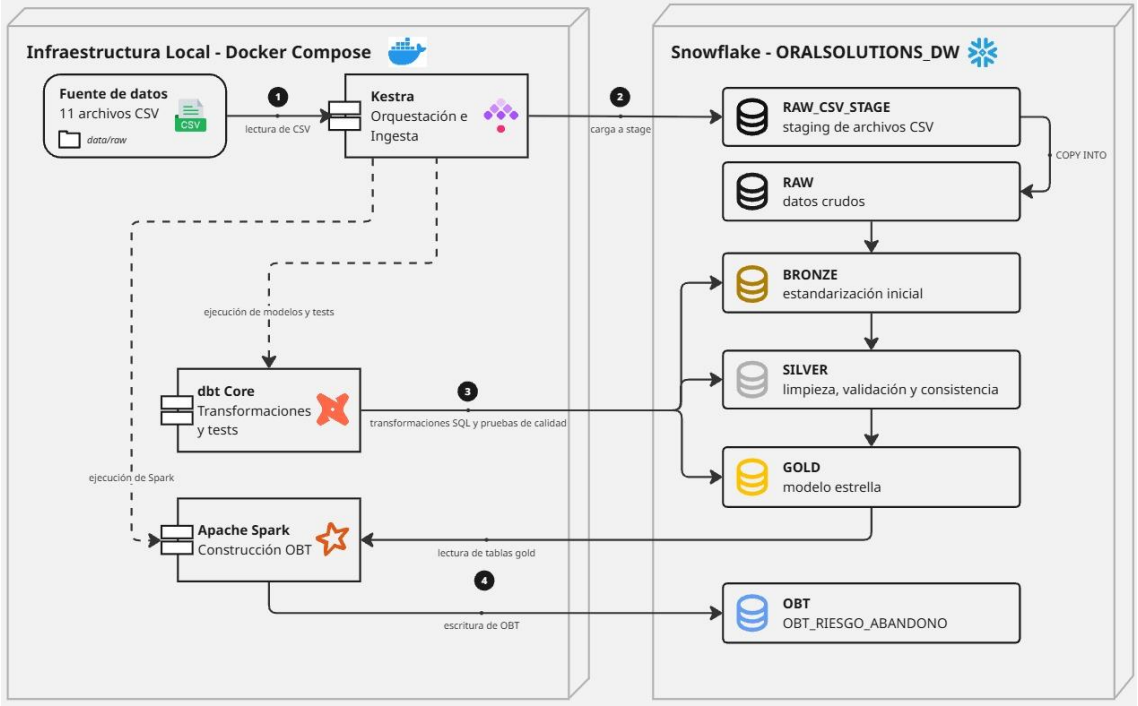


Figura 1. Arquitectura y flujo de datos del pipeline ELT de OralSolutions.

La infraestructura local se despliega mediante Docker Compose, integrando Kestra para la orquestación y Apache Spark para el procesamiento de datos, mientras que Snowflake centraliza el almacenamiento y las transformaciones. Kestra coordina la ingesta de 11 archivos CSV hacia un stage de Snowflake, su carga en Raw, las transformaciones y validaciones mediante dbt Core y la construcción de la OBT mediante Spark. El enfoque ELT permite preservar los datos de origen y transformarlos en Snowflake a través de las capas Bronze (tipificación), Silver (limpieza y validación) y Gold (modelo dimensional). Finalmente, Spark integra las tablas de Gold en OBT_RIESGO_ABANDONO, destinada a la siguiente etapa predictiva. En la figura, las líneas discontinuas representan la orquestación de Kestra, y las continuas el flujo de datos.

2. Ingesta

- **Fuente y granularidad:** Se utilizó un conjunto de datos sintéticos adaptado al caso OralSolutions, tomando como referencia el conjunto público “Dental Clinic Appointments and Billing Dataset” de DatabaseSample (2026). Comprende 11 archivos CSV con registros históricos de 2024-2025, cuya granularidad

corresponde a entidades individuales como pacientes, citas, planes de tratamiento, eventos de sesión y seguimientos.

- **Trigger y frecuencia:** El pipeline maestro se programó mediante un trigger diario (0 2 * * *) a las 02:00, zona America/Guayaquil, para ejecutar automáticamente la ingesta, las transformaciones dbt y la construcción de la OBT con Spark.
- **Proceso de carga:** Kestra procesa secuencialmente los 11 CSV desde data/raw, los transfiere a RAW_CSV_STAGE en Snowflake y utiliza COPY INTO para cargarlos en tablas auxiliares (_INCOMING). Posteriormente, incorpora en RAW los registros cuyos identificadores no existen en el destino.
- **Manejo de errores y retries:** Se configuraron tres intentos con retroceso exponencial, intervalo inicial de 5 s y máximo de 30 s. Ante fallos no recuperados, Kestra detiene el flujo y registra el error con su identificador de ejecución.
- **Backfill histórico:** Se implementó un flujo independiente con fechas parametrizadas para recuperar citas faltantes desde el stage hacia RAW.APPOINTMENTS, aplicando filtros temporales y controles de unicidad por identificador. Se priorizó esta entidad por su relevancia para reconstruir el historial de atención de los pacientes.

Validación de ejecución. El pipeline maestro finalizó en 6 min 38 s y el backfill completó sus seis tareas en 18,44 s, conservando 7 788 citas con identificadores únicos y no nulos. Una prueba controlada verificó los tres intentos configurados y la activación del manejador global de errores.

3. Data Quality

3.1. Perfilado general de los datos

El conjunto comprende 38 603 registros distribuidos en 11 tablas, con una completitud global del 93,59%, calculada sobre 259 510 celdas evaluadas. No se identificaron filas completamente duplicadas, mientras que se detectaron 16.622 valores nulos. La Tabla 1 presenta el resumen del perfilado de los datos crudos.

Tabla 1. Resumen del perfilado general de datos crudos de OralSolutions

Tabla	Registros	Columnas	Duplicados	Valores faltantes	Columnas con faltantes	Completitud
appointments	7 788	6	0	1 977	1	95,77%
dentists	5	5	0	0	0	100%
insurers	4	4	0	0	0	100%
invoices	7 788	6	0	1 345	1	97,12%
missed_appointments	1 500	5	0	0	0	100%
patient_followups	1 243	5	0	50	1	99,20%
patients	2 500	8	0	1 652	4	91,74%
procedures	10	6	0	0	0	100%
treatment_lines	7 956	6	0	0	0	100%
treatment_plans	3 015	10	0	3 655	2	87,88%
treatment_sessions	6 794	8	0	7 943	3	85,39%
Total / Global	38 603	69	0	16 622	12	93,59%

Las tablas con menor completitud fueron treatment_sessions (85,39%), treatment_plans (87,88%) y patients (91,74%). Sin embargo, la completitud mide la presencia física de valores y no necesariamente la calidad funcional de los datos, pues incluye campos cuya ausencia puede estar justificada por reglas de negocio.

3.2. Diagnóstico de calidad y decisiones de tratamiento

Se realizó un análisis detallado de las 11 tablas, evaluando completitud, precisión, consistencia y validez mediante reglas de integridad referencial, formatos, rangos y coherencia temporal y operativa. Se identificaron anomalías corregibles, ausencias justificadas por reglas de negocio y registros que requieren revisión. La Tabla 2 presenta los principales hallazgos y las decisiones adoptadas para su tratamiento mediante dbt.

Tabla 2. Principales hallazgos de calidad y decisiones de limpieza de OralSolutions.

Problema o hallazgo	Evidencia	Acción	Justificación
Correos inválidos (patients)	34 (1,36 %)	Normalizar y convertir a NULL los no recuperables	Evitar información de contacto inválida
Fechas de registro ausentes (patients)	200 (8,00 %)	Conservar NULL	No generar fechas históricas artificiales
Coberturas ausentes (appointments)	1.977 (25,39 %)	Conservar NULL	Corresponden a pacientes sin seguro
Motivos de interrupción o pausa ausentes (treatment_plans)	43 casos: 14 interrumpidos y 29 pausados	Conservar causa desconocida	No asumir abandono o justificación clínica
Números de sesión repetidos (treatment_sessions)	1.396 registros (20,55 %)	Conservar intentos	Representan reintentos por cancelación o inasistencia
Inconsistencias temporales (treatment_sessions)	5 fechas planificadas y 3 realizadas anteriores al inicio del plan	Señalar para revisión	Evitar modificar fechas sin evidencia
Ausencias sin sesión vinculada (missed_appointments)	351 (23,40 %)	Conservar registros	Pueden corresponder a citas independientes
Métodos de contacto no estandarizados (patient_followups)	18 (1,45 %)	Aplicar LOWER(TRIM())	Unificar categorías equivalentes
Resultados de contacto faltantes (patient_followups)	50 (4,02 %)	Conservar NULL	No atribuir resultados sin evidencia
Contactos posteriores al cierre (patient_followups)	901 (72,49 %)	Conservar y controlar temporalidad	Evitar información futura en las predicciones
Fechas de pago ausentes (invoices)	1.345 (17,27 %)	Conservar NULL	Corresponden a facturas pendientes o dadas de baja

Las tablas dentists, insurers, procedures y treatment_lines no presentaron anomalías bajo las reglas evaluadas. Se priorizó preservar los registros y aplicar con dbt la estandarización, conversión de tipos y validaciones de calidad. Los valores faltantes se conservaron cuando su ausencia era coherente con el negocio, mientras que las inconsistencias no verificables se mantuvieron identificadas para revisión.

4. Transformaciones y modelado

4.1. Transformaciones Bronze y Silver

Las transformaciones se implementaron mediante dbt Core sobre Snowflake, utilizando modelos SQL organizados en pset_2/dbt/models/bronze/ y pset_2/dbt/models/silver/. En Bronze se estandarizaron los tipos de datos de las 11 tablas Raw mediante conversiones tolerantes a errores con TRY_CAST, normalizando la representación de identificadores, fechas y valores numéricos. En Silver se aplicaron las reglas de limpieza derivadas del diagnóstico de calidad, incluyendo validación de correos electrónicos, normalización de métodos de contacto mediante LOWER(TRIM()) y tratamiento de cadenas vacías. Se conservaron los valores nulos justificados y los registros históricos sin evidencia suficiente para corregirlos.

4.2. Modelado dimensional Gold

A partir de Silver se construyó un esquema de estrella mediante modelos SQL y configuraciones YAML ubicados en pset_2/dbt/models/gold/, compuesto por una tabla de hechos FACT_SESIONES_TRATAMIENTO y cinco dimensiones: DIM_PACIENTE, DIM_ODONTOLOGO, DIM_PROCEDIMIENTO, DIM_ESTADO y DIM_FECHA.

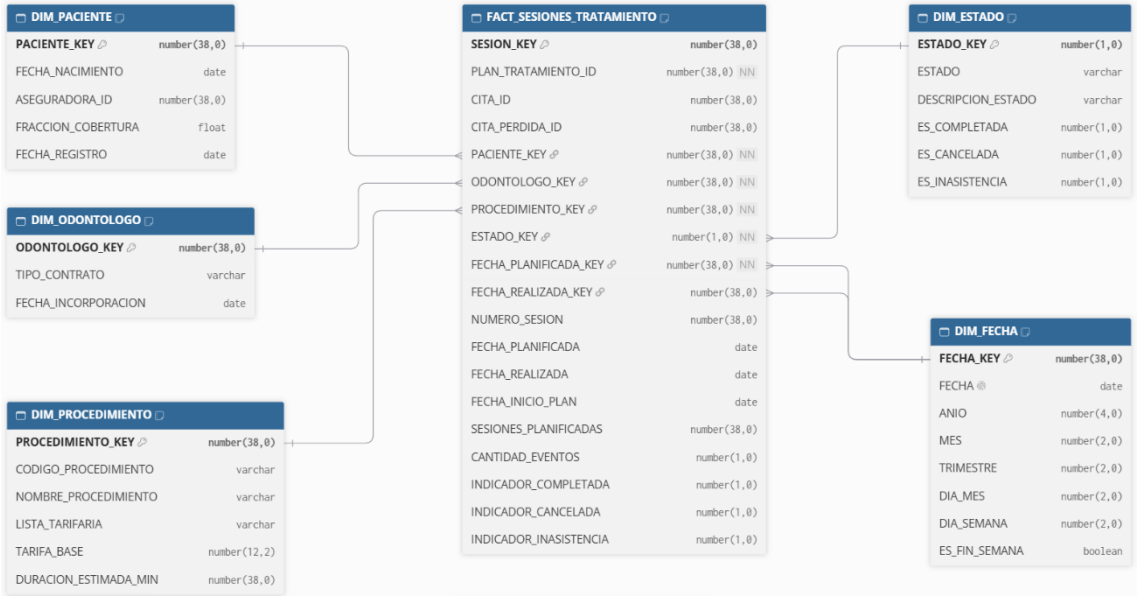


Figura 2. Modelo dimensional en estrella de la capa Gold de OralSolutions.

El grano de FACT_SESIONES_TRATAMIENTO corresponde a un evento individual de sesión asociado a un plan de tratamiento, identificado mediante SESION_KEY. Esta granularidad permite conservar múltiples intentos de una misma sesión lógica y analizar el historial de asistencia, cancelaciones e inasistencias. La tabla contiene 6 794 eventos, indicadores de asistencia y una medida unitaria para su contabilización. Las dimensiones permiten analizar los eventos por paciente, odontólogo, procedimiento, estado y fecha; DIM_FECHA cumple dos roles: fecha planificada y fecha de realización.

4.3. Dependencias y validaciones dbt

Las dependencias entre modelos se gestionaron mediante source() y ref(). Las pruebas se definieron en archivos YAML y SQL dentro de dbt/models/ y dbt/tests/silver/ y dbt/tests/gold/, incluyendo not_null, unique, relationships, accepted_values y validaciones de reglas de negocio sobre estados, fechas y coberturas. La última ejecución registrada reportó 177 pruebas aprobadas, verificando la integridad estructural y las reglas de calidad implementadas.

5. Spark y OBT

5.1. Construcción de la OBT

La construcción de la One Big Table (OBT) se implementó mediante PySpark en pset_2/spark/build_obt.py, utilizando el conector Spark–Snowflake para leer la tabla de hechos y las cinco dimensiones de Gold.

El grano de OBT_RIESGO_ABANDONO corresponde a un punto candidato de predicción por paciente, tratamiento y sesión atendida de referencia, siempre que exista continuidad planificada pendiente. Se seleccionaron sesiones completadas con fecha

de realización, excluyendo eventos que no representan oportunidades de intervención preventiva. Mediante funciones de ventana se calcularon antecedentes de sesiones, cancelaciones e inasistencias utilizando eventos anteriores a la fecha de referencia. Se excluyeron eventos del mismo día para evitar ambigüedades temporales en el cálculo de las variables históricas.

5.2. Validación y uso del modelo

Antes de la integración se verificó la unicidad de las claves y la integridad referencial. El proceso Spark incorpora controles para comprobar que los joins conserven los 6 794 registros de Gold sin pérdidas ni duplicaciones. Posteriormente, se aplicaron los criterios de selección, obteniendo 3 435 puntos candidatos de predicción en OBT_RIESGO_ABANDONO, con identificadores de sesión únicos y sin claves nulas, como se evidencia en la Figura 3.

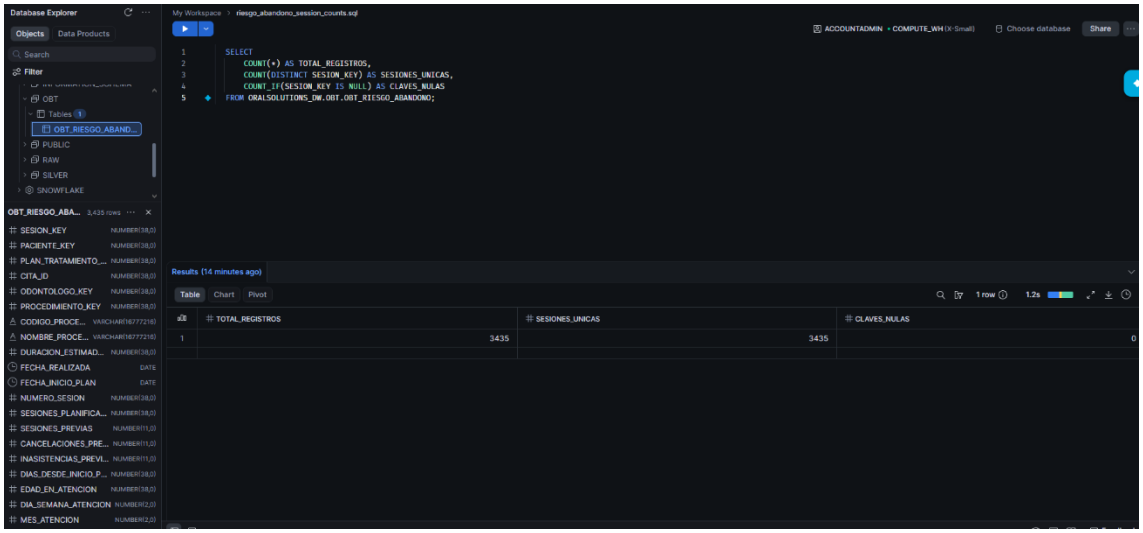


Figura 3. Validación de registros, unicidad y valores nulos en la OBT de OralSolutions.

El esquema estrella de Gold se utilizará para consultas analíticas sobre pacientes, tratamientos, procedimientos y sesiones, aprovechando sus dimensiones y la granularidad de los eventos clínicos. En cambio, la OBT se utilizará como conjunto de entrada para el futuro modelo predictivo, al consolidar los atributos históricos disponibles en cada punto de predicción y evitar uniones adicionales.

6. Batch vs Streaming

Se implementó procesamiento por lotes (batch) debido a la naturaleza del negocio odontológico y a los requisitos de latencia del problema. Los datos de citas, sesiones y tratamientos se generan conforme a la actividad clínica, mientras que la identificación del riesgo de abandono permite realizar acciones preventivas durante los días posteriores a la atención. Por ello, una actualización diaria resulta suficiente, implementándose mediante Kestra a las 02:00 (America/Guayaquil), sin requerir procesamiento en tiempo real.

Una arquitectura streaming se justificaría si el caso de uso exigiera detectar eventos y activar intervenciones inmediatas, como identificar una inasistencia o cancelación y generar una alerta para contactar al paciente en minutos. Esto requeriría una fuente

continua de eventos, procesamiento incremental y mecanismos de notificación de baja latencia, incrementando la complejidad de integración y operación sin aportar un beneficio proporcional a las necesidades actuales.

7. Limitaciones

- **Inconsistencias temporales:** Se identificaron ocho registros de sesiones con fechas anteriores al inicio del tratamiento. Estos casos se conservaron para revisión, evitando modificaciones sin evidencia. En la siguiente etapa se evaluará su corrección o exclusión para garantizar la coherencia cronológica.
- **Información clínica incompleta:** Existen 43 tratamientos pausados o interrumpidos sin una causa documentada, lo que dificulta distinguir entre abandono y suspensión justificada. Estos casos requerirán criterios de clasificación o exclusión antes del entrenamiento.
- **Horizonte de observación:** Los puntos de predicción cercanos al final del período histórico podrían no disponer de 60 días completos de seguimiento. Será necesario identificar estas observaciones antes de construir el target, evitando clasificarlas como abandono por ausencia de registros futuros.
- **Preparación del conjunto predictivo:** La OBT contiene 3 435 puntos candidatos, pero aún no incorpora la variable objetivo de abandono a 60 días. Será necesario validar la continuidad clínica y garantizar que las variables utilizadas correspondan únicamente a información disponible hasta cada fecha de predicción, evitando fugas de data leakage.

Anexos

Anexo A. Diagnóstico detallado de calidad de datos

Tabla A.1. PATIENTS

Registros evaluados: 2 500 **| Columnas:** 8 **| Comprobaciones:** 21

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos, inválidos o duplicados	Conservar identificadores.
email	Completitud	180 nulos (7,20%)	Conservar NULL; no inventar contactos.
email	Validez	34 formatos inválidos (1,36%)	Normalizar o convertir a NULL si no son recuperables.
registered_at	Completitud	200 nulos (8,00%)	Conservar NULL; evitar fechas artificiales.
insurer_id	Completitud	636 nulos (25,44%)	Conservar; representan pacientes sin aseguradora.
cover_fraction	Completitud	636 nulos (25,44%)	Conservar; la cobertura no aplica sin aseguradora.
birth_date	Validez	Sin fechas implausibles detectadas	Conservar y validar reglas temporales.

Decisión: Mantener los 2.500 pacientes, normalizando los correos inválidos sin eliminar registros por ausencia de información opcional.

Tabla A.2. APPOINTMENTS

Registros evaluados: 7 788 **| Columnas:** 6 **| Comprobaciones:** 19

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
patient_id	Consistencia	0 referencias inexistentes	Mantener integridad con pacientes.
dentist_id	Consistencia	0 referencias inexistentes	Mantener integridad con odontólogos.
scheduled_at	Consistencia temporal	0 citas anteriores al ingreso del odontólogo	Conservar fechas.
visit_type	Validez	4 categorías válidas	Conservar y validar dominio.
cover_fraction	Completitud	1 977 nulos (25,39 %)	Conservar; corresponden a pacientes sin seguro.

Decisión: Preservar las 7.788 citas sin imputar coberturas, verificando su coherencia con la información del paciente.

Tabla A.3. TREATMENT_PLANS

Registros evaluados: 3 015 **| Columnas:** 10 **| Comprobaciones:** 30

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
patient_id, dentist_id, procedure_id	Consistencia	Sin referencias inexistentes	Mantener relaciones.
start_date	Validez	Sin fechas inválidas	Conservar.
planned_sessions	Validez	Sin cantidades inválidas	Conservar.
estimated_cost	Validez	Sin valores negativos	Conservar.
status	Validez	4 estados válidos	Mantener categorías originales.
end_date	Completitud	755 nulos (25,04%)	Conservar; 647 planes activos y 108 pausados.
closure_reason	Completitud	2 900 nulos (96,19%)	Conservar cuando no aplique.
closure_reason	Completitud	14 interrupciones y 29 pausas sin motivo	Mantener causa desconocida; no asumir abandono.

Decisión: Conservar los 3.015 tratamientos, diferenciando las ausencias justificadas de los 43 casos que requieren revisión clínica.

Tabla A.4. TREATMENT_SESSIONS

Registros evaluados: 6 794 **| Columnas:** 8 **| Comprobaciones:** 32

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
treatment_plan_id	Consistencia	Sin referencias inexistentes	Mantener relación con planes.
session_number	Consistencia	1 396 registros repetidos (20,55%) en 698 grupos	Conservar; representan posibles reintentos.

planned_date	Consistencia temporal	5 fechas anteriores al inicio del plan (0,07%)	Señalar para revisión; no modificar sin evidencia.
completed_at	Consistencia temporal	3 fechas anteriores al inicio del plan (0,04%)	Conservar y revisar cronología.
status	Validez	3 estados válidos	Conservar completed, cancelled y missed.
appointment_id	Consistencia	5 645 sesiones completadas vinculadas a citas	Validar integridad referencial.
missed_appointment_id	Consistencia	1 149 sesiones no realizadas vinculadas a ausencias	Conservar y validar referencias.

Decisión: Mantener los 6 794 eventos individuales, preservando los números de sesión repetidos como posibles reintentos y señalando las ocho inconsistencias temporales para revisión posterior.

Tabla A.5. Diagnóstico de calidad de MISSED_APPOINTMENTS

Registros evaluados: 1 500 **| Columnas:** 5 **| Comprobaciones:** 18

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
patient_id, dentist_id	Consistencia	Sin referencias inexistentes	Mantener relaciones.
scheduled_at	Validez	Sin fechas inválidas o discrepancias con sesiones vinculadas	Conservar.
outcome	Validez	3 categorías válidas	Conservar estados originales.
Relación con sesiones	Consistencia	351 ausencias sin sesión (23,40%)	Conservar; pueden ser citas independientes del tratamiento.

Decisión: Mantener los 1 500 registros. Las 1 149 ausencias vinculadas a sesiones presentan estados coherentes, mientras que los 351 restantes se conservan como eventos independientes.

Tabla A.6. PATIENT_FOLLOWUPS

Registros evaluados: 1 243 **| Columnas:** 5 **| Comprobaciones:** 14

Campo	Dimensión	Evidencia	Acción y justificación

id	Consistencia	0 nulos o duplicados	Conservar identificadores.
treatment_plan_id	Consistencia	Sin referencias inexistentes	Mantener relación con planes.
contact_method	Consistencia	18 valores no estandarizados (1,45%)	Aplicar LOWER(TRIM()).
contact_result	Completitud	50 valores faltantes (4,02%)	Conservar NULL; no atribuir respuestas.
contact_date	Consistencia temporal	901 contactos posteriores al cierre (72,49 %)	Conservar; controlar disponibilidad temporal.

Decisión: Preservar los 1 243 contactos, normalizar métodos y evitar utilizar seguimientos posteriores a la fecha de referencia como información predictiva.

Tabla A.7. DENTISTS

Registros evaluados: 5 **| Columnas:** 5 **| Comprobaciones:** 10

Campo	**Dimensión**	**Evidencia**	**Acción y justificación**
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
first_name, last_name	Completitud	0 faltantes	Conservar.
contract	Validez	3 full_time y 2 associate	Conservar categorías válidas.
joined_on	Validez	Sin fechas inválidas o futuras	Conservar.

Decisión: Mantener los cinco odontólogos sin imputaciones ni exclusiones.

Tabla A.8. INSURERS

Registros evaluados: 4 **| Columnas:** 4 **| Comprobaciones:** 9

Campo	**Dimensión**	**Evidencia**	**Acción y justificación**
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
scheme	Validez	4 valores accepted_plans	Conservar categoría válida.
plan_name	Consistencia	Sin nombres duplicados	Conservar.
cover_fraction	Validez	Sin valores fuera del rango [0, 1]	Conservar y validar rango.

Decisión: Mantener las cuatro aseguradoras sin modificaciones de contenido.

Tabla A.9. PROCEDURES

Registros evaluados: 10 **| Columnas:** 6 **| Comprobaciones:** 12

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
code	Consistencia	Sin códigos duplicados	Mantener unicidad.
name	Completitud	0 faltantes	Conservar.
fee	Validez	Sin tarifas negativas	Conservar.
chair_minutes	Validez	Duraciones enteras positivas	Conservar.
list_name	Validez	10 valores fee_list	Mantener categoría válida.

Decisión: Conservar los diez procedimientos y sus tarifas, sin imputaciones ni exclusiones.

Tabla A.10. TREATMENT_LINES

Registros evaluados: 7 956 **| Columnas:** 6 **| Comprobaciones:** 20

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.
appointment_id, procedure_id	Consistencia	Sin referencias inexistentes	Mantener relaciones.
fee	Precisión	Sin diferencias con tarifas de referencia	Conservar importe.
insurer_amount	Validez	Sin valores negativos o superiores a la tarifa	Conservar importe.
patient_amount	Validez	Sin valores negativos o superiores a la tarifa	Conservar importe.
Distribución de importes	Consistencia	Sin descuadres económicos	Mantener valores originales.

Decisión: Conservar los 7.956 registros y aplicar conversiones numéricas y pruebas de conciliación económica con dbt.

Tabla A.11. INVOICES

Registros evaluados: 7 788 **| Columnas:** 6 **| Comprobaciones:** 20

Campo	Dimensión	Evidencia	Acción y justificación
id	Consistencia	0 nulos o duplicados	Conservar identificadores.

appointment_id	Consistencia	Sin referencias inexistentes o duplicadas	Mantener relación con citas.
invoice_no	Consistencia	Sin números de factura duplicados	Conservar.
issued_on	Validez	Sin fechas anteriores a la cita o futuras	Conservar.
status	Validez	3 estados válidos	Mantener paid, outstanding y written_off.
paid_on	Completitud	1.345 nulos (17,27 %)	Conservar; 967 facturas pendientes y 378 dadas de baja.

Decisión: Mantener las 7 788 facturas, preservando las fechas de pago nulas cuando no existe un pago registrado.

Anexo B. Ejecución y orquestación del pipeline

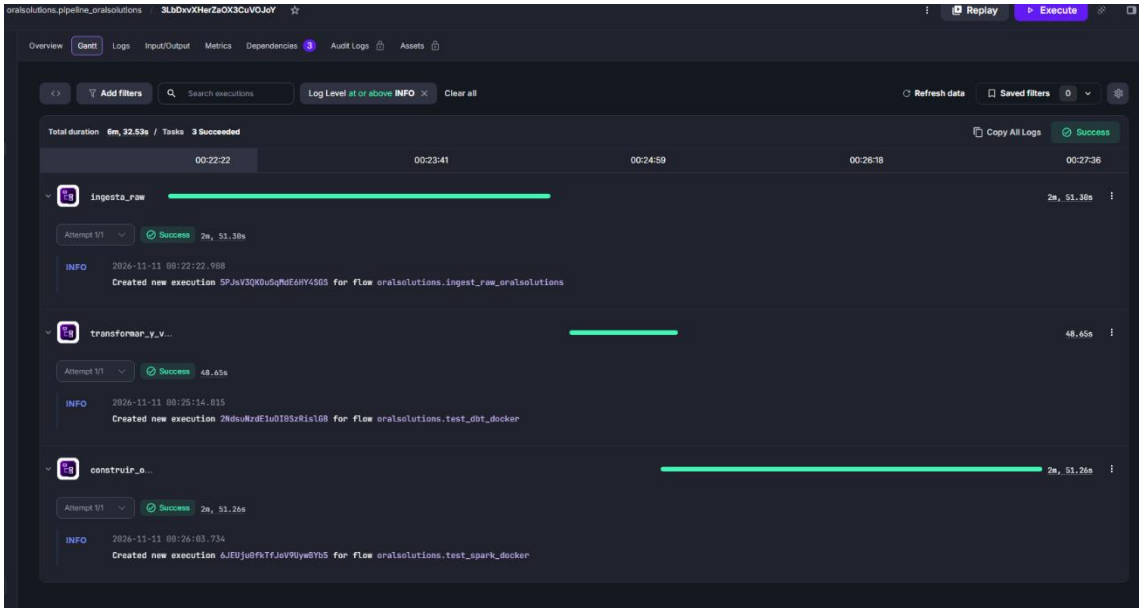


Figura B.1. Ejecución del pipeline maestro

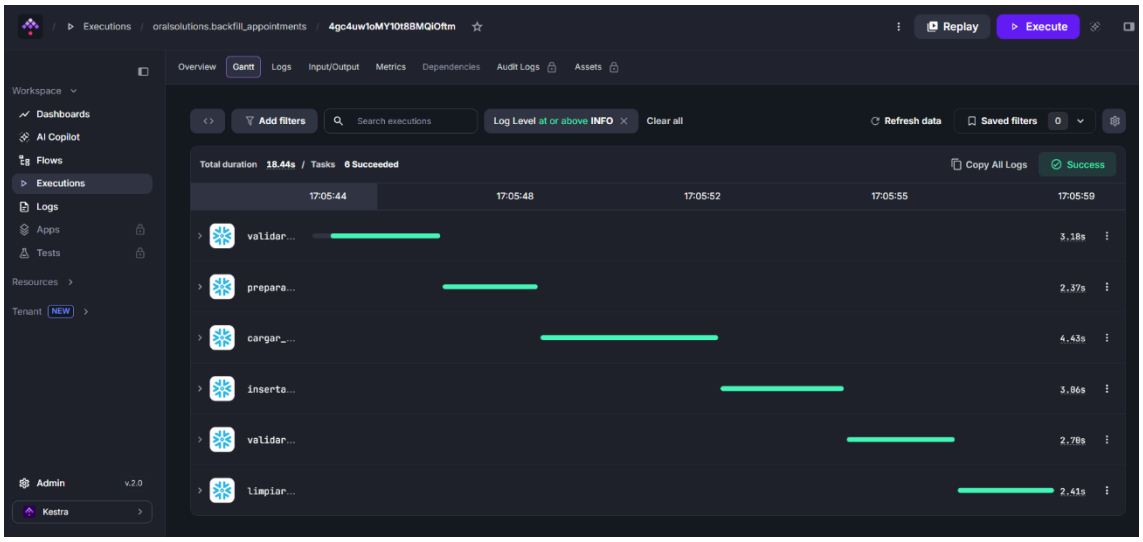


Figura B.2. Ejecución del backfill histórico

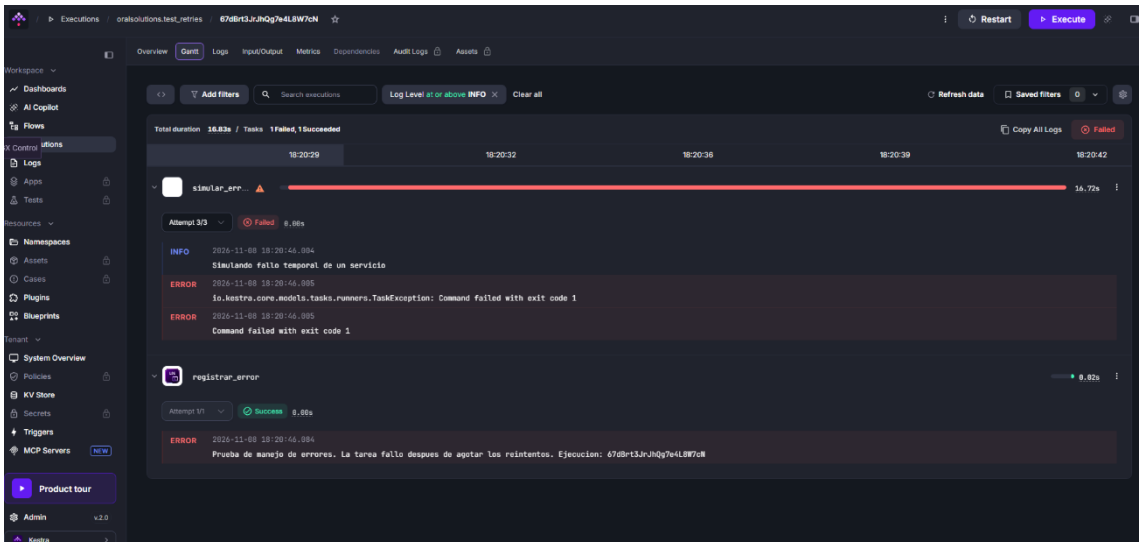


Figura B.3. Validación de reintentos y manejo de errores

Anexo C. Validaciones dbt

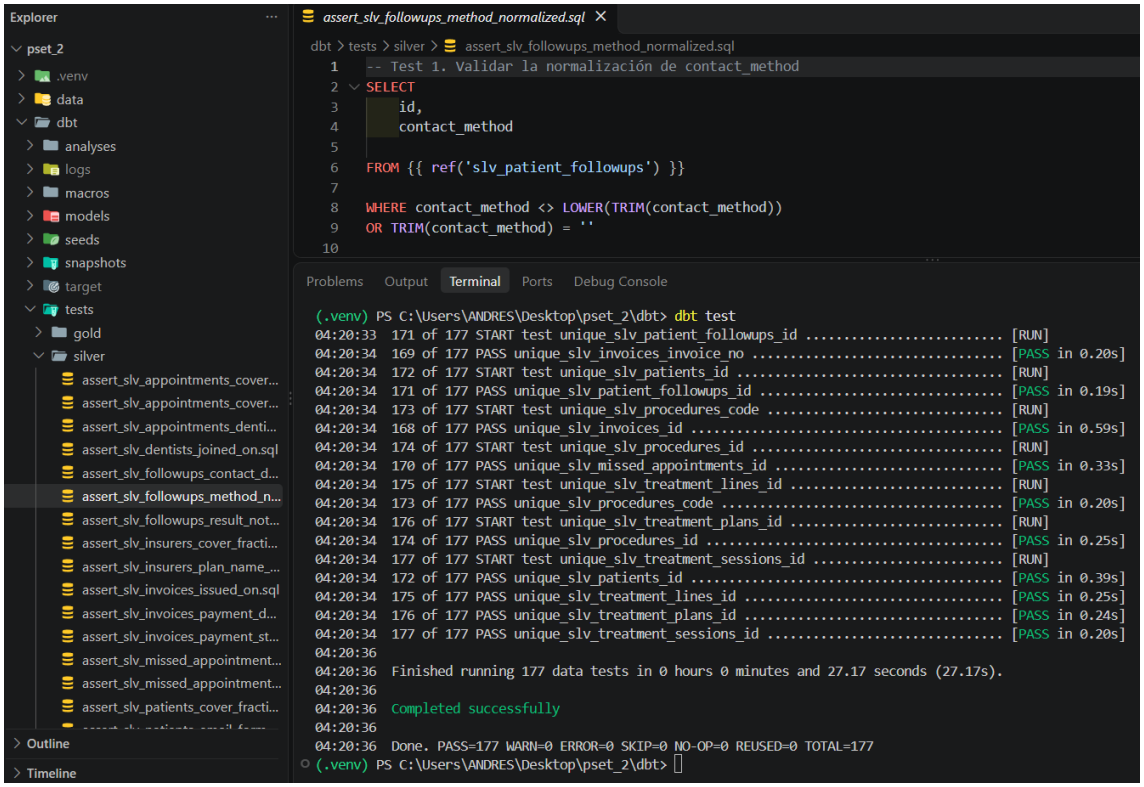


Figura C.1. Resultado de la ejecución de pruebas de calidad con dbt Core.

Anexo D. Construcción y validación de la OBT

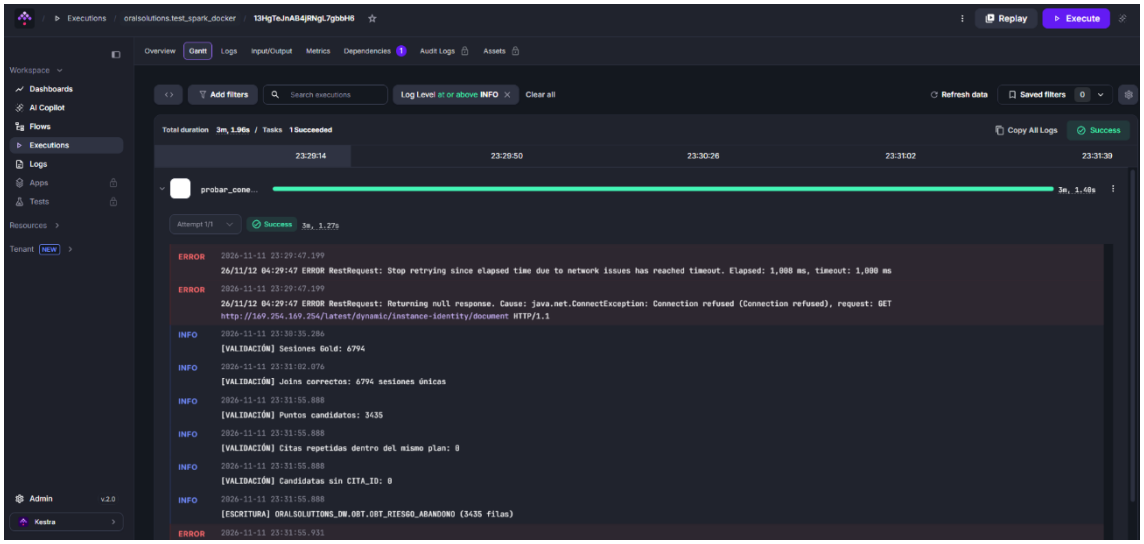


Figura D.1. Validación de la conservación de registros y unicidad durante la integración de Gold

La ejecución de build_obt.py, mediante Apache Spark y orquestada por Kestra, finalizó exitosamente en 3 min 1,96 s. Se verificó que los joins conservaron las 6.794 sesiones originales sin duplicados. Posteriormente, se generaron 3.435 puntos candidatos de predicción, sin citas repetidas dentro de un mismo tratamiento ni registros sin identificador de cita. Finalmente, la OBT se almacenó correctamente en Snowflake, sin calcular todavía la variable objetivo de abandono a 60 días.